Curs 4

Programare Paralela si Distribuita

Message Passing Interface - MPI

MPI: Message Passing Interface

- MPI -documentation
 - http://mpi-forum.org
- Tutoriale:
 - https://computing.llnl.gov/tutorials/mpi/
 - **—** ...

MPI

- specificatie de biblioteca(API) pentru programare paralela bazata pe transmitere de mesaje;
- propusa ca standard de producatori si utilizatori;
- gandita sa ofere performanta mare pe masini paralele dar si pe clustere;

Istoric

- Apr 1992: Workshop on Standards for Message Passing in a Distributed Memory Environment, sponsored by the Center for Research on Parallel Computing, Williamsburg, Virginia=> Preliminary draft proposal
- Nov 1992: Minneapolis. MPI draft proposal (MPI1) from ORNL presented.
- Nov 1993: Supercomputing 93 conference draft MPI standard presented.
- May 1994: Final version of MPI-1.0 released
- MPI-1.1 (Jun 1995)
- MPI-1.2 (Jul 1997)
- MPI-1.3 (May 2008).
- 1998: MPI-2 picked up where the first MPI specification left off, and addressed topics which went far beyond the MPI-1 specification.
- MPI-2.1 (Sep 2008)
- MPI-2.2 (Sep 2009)
- Sep 2012: The MPI-3.0 standard approved.
- MPI-3.1 (Jun 2015)
- MPI-4

PPD - Curs 4

5

Implementari

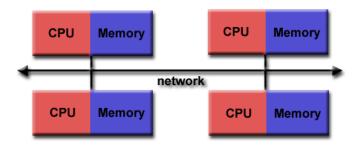
Exemple:

- MPICH –
- Open MPI –
- IBM MPI -
- IntelMPI (not free)
- Links:

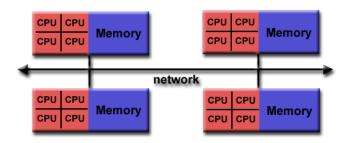
http://www.dcs.ed.ac.uk/home/trollius/www.osc.edu/mpi/

Modelul de programare

Initial doar pt DM



Ulterior si pt SM



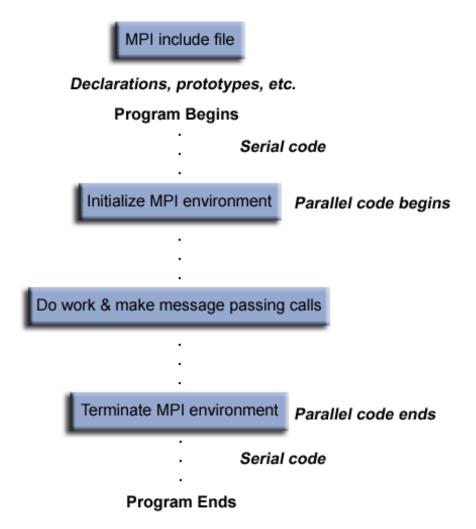
Platforme suportate

- Distributed Memory
- Shared Memory
- Hybrid

PPD - Curs 4

7

Structura program MPI



Hello World in MPI

```
#include "mpi.h"
                                    compilare
                                    $ mpicc hello.c -o hello
#include <stdio.h>
                                    executie
int main(int argc, char **argv)
                                    $ mpirun -np 4 hello
   int namelen, myid, numprocs;
   MPI_Init( &argc, &argv );
       MPI_Comm_size(MPI_COMM_WORLD,&numprocs);
       MPI_Comm_rank(MPI_COMM_WORLD,&myid);
       printf( "Process %d / %d : Hello world\n", myid, numprocs);
                                             Process 0 / 4 : Hello world
   MPI_Finalize();
                                             Process 2 / 4: Hello world
   return 0;
                                             Process 1 / 4: Hello world
                                             Process 3 / 4: Hello world
```

Formatul functiilor MPI

```
rc = MPI_Xxxxx(parameter, ... )
Exemplu:
rc=MPI_Bsend( &buf, count, type, dest, tag, comm)
```

Cod de eroare: Intors ca "rc". MPI_SUCCESS pentru succes

Comunicatori si grupuri

- MPI foloseste obiecte numite comunicatori si grupuri pentru a defini ce colectii de procese pot comunica intre ele. Cele mai multe functii MPI necesita specificarea unui comunicator ca argument.
- Pentru simplitate exista comunicatorul predefinit care include toate procesele MPI numit MPI_COMM_WORLD.

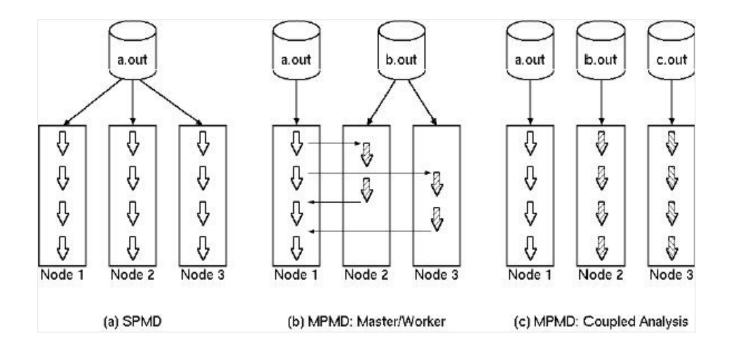
Rangul unui proces

- Intr-un comunicator, fiecare proces are un identificator unic, rang. El are o valoare intreaga, unica in sistem, atribuita la initializarea mediului.
- Utilizat pentru a specifica sursa si destinatia mesajelor.
- De asemenea se foloseste pentru a controla executia programului:
 e.g: daca rank=0 fa ceva / daca rank=1 fa altceva, etc.

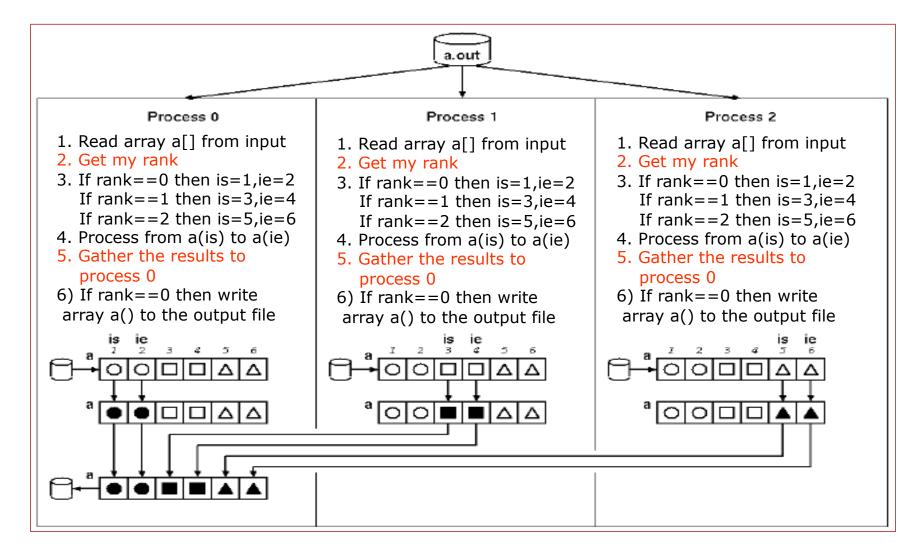
SPMD/MPMD

Modele de calcul paralel in sisteme cu memorie distribuita

SPMD (Single Program Multiple Data) (Fig a) MPMD (Multiple Program Multiple Data) (Fig b,c)



Modelul SPMD – Single Program Multiple Data



MPI. Clase de functii

- Functii de management mediu
- Functii de comunicatie punct-la-punct
- Operatii colective
- Grupuri de procese/Comunicatori
- Topologii (virtuale) de procese

Functii de management mediu

• initializare, terminare, interogare mediu

```
    MPI_Init - initializare mediu
        MPI_Init (&argc,&argv)
        MPI_INIT (ierr)
```

•MPI_Comm_size - determina numarul de procese din grupul asociat unui com.

MPI_Comm_size (comm,&size)
MPI_COMM_SIZE (comm,size,ierr)

•MPI_Comm_rank - determina rangul procesului apelant in cadrul unui com.

MPI_Comm_rank (comm,&rank)
MPI_COMM_RANK (comm,rank,ierr)

• MPI_Abort -opreste toate procesele asociate unui comunicator

MPI_Abort (comm,errorcode)
MPI_ABORT (comm,errorcode,ierr)

• MPI_Finalize -finalizare mediu MPI

MPI_Finalize ()
MPI_FINALIZE (ierr)

Exemplu

• initializare, terminare, interogare mediu

```
#include "mpi.h"
#include <stdio.h>
int main(int argc, char *argv[] )
int numtasks, rank, rc;
rc = MPI Init(&argc, &argv);
if (rc != MPI SUCCESS) {
      printf ("Error starting MPI program. Terminating.\n");
      MPI Abort(MPI COMM WORLD, rc);
MPI Comm size(MPI COMM WORLD, &numtasks);
MPI Comm rank (MPI COMM WORLD, &rank);
printf ("Number of tasks= %d My rank= %d\n", numtasks,rank);
      /***** do some work ******/
MPI Finalize();
}
```

Executie

\$ mpirun -np 4 test

- se creeaza 4 instante de process si fiecare executa acelasi program executabil
- Intre init si finalize se pot apela functii MPI
 - context in care interactione dinte procese este posibila prin functiile
 MPI

Comunicatie punct-la-punct

Transferul de mesaje intre 2 taskuri MPI distincte intr-un anumit sens.

• Tipuri de operatii punct-la-punct

Exista diferite semantici pentru operatiile de send/receive :

- •Synchronous send
- •Blocking send / blocking receive
- •Non-blocking send / non-blocking receive
- •Buffered send
- •Combined send/receive
- •"Ready" send
- •o rutina send poate fi utilizata cu orice alt tip de rutina receive
- •rutine MPI asociate (wait,probe)

Comunicatie punct-la-punct-Operatii blocate vs ne-blocante

send are 4 moduri de comunicare:

Standard Buffered Synchronous Ready

Fiecare poate fi **blocking** or **non-blocking**

receive are 2 moduri de comunicare blocking non-blocking

Operatii blocante

O operatie de *send blocanta* va "returna"(se va finaliza) doar atunci cand zona de date folosita pentru trimitere poate fi reutilizata, fara sa afecteze datele primite de destinatar. *Operatii ne-blocante*

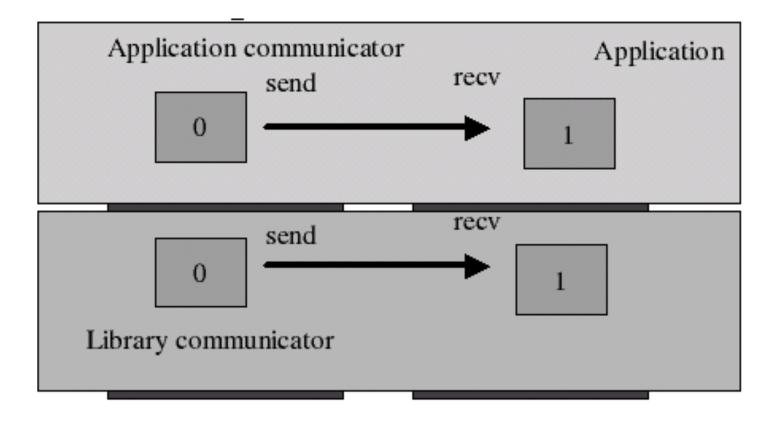
Returneaza controlul imediat, notifica libraria care se va ocupa de transfer. Exista functii speciale de asteptare/interogare a statusului transferului.

Comunicatie punct-la-punct

Operatii blocate vs ne-blocante

Blocking send	MPI_Send(buffer,count,type,dest,tag,comm)
Blocking receive	MPI_Recv(buffer,count,type,source,tag,comm, status)
Blocking Probe	MPI_Probe (source,tag,comm,&status)
Non-blocking send	MPI_Isend(buffer,count,type,dest,tag,comm, request)
Non-blocking receive	MPI_Irecv(buffer,count,type,source,tag,comm, request)
Wait	MPI_Wait (&request,&status)
Test	MPI_Test (&request,&flag,&status)
Non-blocking probe	MPI_Iprobe (source,tag,comm,&flag,&status)

Comunicatii send-recv



Determinism si nedeterminism

- Modele de programare paralela bazate pe transmitere de mesaje sunt implicit nedeterministe: ordinea in care mesajele transmise de la doua procese A si B la al treilea C, nu este definita.
 - Este responsabilitatea programatorul de a asigura o executie determinista, daca aceasta se cere.
- In modelul bazat pe transmitere pe canale de comunicatie, determinismul este garantat prin definirea de canale separate pentru comunicatii diferite, si prin asigurarea faptului ca fiecare canal are doar un singur "scriitor" si un singur "cititor".

Determinism in MPI

- Pentru obtinerea determinismului in MPI, sistemul trebuie sa adauge anumite informatii datelor pe care programul trebuie sa le trimita. Aceste informatii aditionale formeaza un asa numit "plic" al mesajului.
- In MPI acesta contine urmatoarele informatii:
 - un comunicator.
 - rangul procesului transmitator
 - rangul procesului receptor
 - un tag (marcaj) este un intreg specificat de catre programator, pentru a se putea face distinctie intre mesaje receptionate de la acelasi proces transmitator.
- Comunicatorul stabileste grupul de procese in care se face transmiterea.

MPI Basic (Blocking) Send

MPI_SEND (start, count, datatype, dest, tag, comm)

- mesajul descris de (start, count, datatype)
- dest id process destinatie

MPI Basic (Blocking) Recv

MPI_Recv (&buf,count,datatype,source,tag,comm,&status)

- MPI permite omiterea specificarii procesului de la care trebuie sa se primeasca mesajul, caz in care se va folosi constanta predefinita: MPI_ANY_SOURCE. (pt send- procesul destinatie trebuie precizat intotdeauna exact.)
 - Marcajul tagul mesajului poate fi inlocuit de MPI_ANY_TAG, daca se considera ca lipsa lui nu poate duce la ambiguitate.
- Ultimul parametru al functiei MPI_Recv, status, returneaza informatii despre datele care au fost receptionate in fapt. Reprezinta o referinta la o inregistrare cu doua campuri: unul pentru sursa si unul pentru tag. Astfel daca sursa a fost MPI_ANY_SOURCE, in status se poate gasi rangul procesului care a trimis de fapt mesajul respective.

MPI Data Types

- MPI_CHAR signed char
- MPI_SHORT signed short int
- MPI_INT signed int
- MPI_LONG signed long int
- MPI_LONG_LONG_INT
- MPI_LONG_LONG signed long long int
- MPI_SIGNED_CHAR signed char
- MPI_UNSIGNED_CHAR unsigned char
- MPI_UNSIGNED_SHORT unsigned short int
- MPI_UNSIGNED unsigned int
- MPI_UNSIGNED_LONG unsigned long int
- MPI_UNSIGNED_LONG_LONG unsigned long long int
- MPI_FLOAT float
- MPI_DOUBLE double
- MPI_LONG_DOUBLE long double

•

Exemplu operatii blocante

```
#include "mpi.h"
#include <stdio.h>
int main(int argc,char *argv[]) {
int numtasks, rank, dest, source, rc, count, tag=1;
char inmsg, outmsg='x';
MPI Status Stat:
MPI Init(&argc, &argv);
MPI Comm size(MPI COMM WORLD, &numtasks);
MPI Comm rank (MPI COMM WORLD, &rank);
if (rank == 0) {
      dest = source = 1;
       rc = MPI Send(&outmsg, 1, MPI CHAR, dest, tag,
      MPI COMM WORLD);
       rc = MPI Recv(&inmsg, 1, MPI CHAR, source, tag,
      MPI COMM WORLD, &Stat);
```

Exemplu operatii blocante (cont)

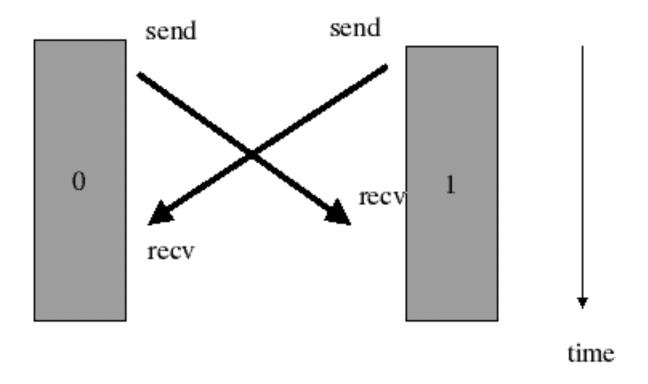
29

MPI deadlocks

Scenariu:

- Presupunem ca avem doua procese in cadrul carora comunicatia se face dupa urmatorul protocol
 - Primul proces trimite date catre cel de-al doilea si asteapta raspunsuri de la acesta.
 - Cel de-al doilea proces trimite date catre primul si apoi asteapta raspunsul de la acesta.
- Daca bufferele sistem nu sunt suficiente se poate ajunge la deadlock.
 Orice comunicatie care se bazeaza pe bufferele sistem este nesigura din punct de vedere al deadlock-ului.
- In orice tip de comunicatie care include cicluri pot apare deadlock-uri.

Deadlock



OPERATII COLECTIVE

• Operatiile colective implica toate procesele din cadrul unui comunicator. Toate procesele sunt membre ale comunicatorului initial, predefinit MPI_COMM_WORLD.

Tipuri de operatii colective:

- •Sincronizare: procesele asteapta toti membrii grupului sa ajunga in punctul de jonctiune.
- •Transfer de date broadcast, scatter/gather, all to all.
- •Calcule colective (reductions) un membru al grupului colecteaza datele de la toti ceilalti membrii si realizeaza o operatie asupra acestora (min, max, adunare, inmultire, etc.)

Observatie:

Toate operatiile colective sunt blocante

```
MPI_Barrier

MPI_Barrier (comm)

MPI_BARRIER (comm,ierr)
```

Fiecare task se va bloca in acest apel pana ce toti membri din grup au ajuns in acest punct

MPI_Bcast Broadcasts a message to all other processes of that group count = 1; source = 1; broadcast originates in task 1 MPI_Bcast(&msg, count, MPI_INT, source, MPI_COMM_WORLD); task 0 task 1 task 2 task 3 7 msg (before)

MPI_Scatter Sends data from one task to all other tasks in a group sendcnt = 1; recvent = 1; task 1 contains the message to be scattered src = 1;MPI_Scatter(sendbuf, sendcnt, MPI_INT, recvbuf, recvcnt, MPI_INT, src, MPI_COMM_WORLD); task 0 task 1 task 2 task 3 1 2 sendbuf (before) 3 4 recvbuf (after) 1 2 3 4

MPI_Gather Gathers together values from a group of processes sendcnt = 1; recvent = 1; messages will be gathered in task 1 src = 1;MPI_Gather(sendbuf, sendcnt, MPI_INT, recvbuf, recvcnt, MPI_INT, src, MPÍ COMM WŌRLĎ); task 0 task 1 task 2 task 3 sendbuf (before) 1 2 3 4 1 2 recvbuf (after) 3

4

MPI_Reduce

Perform and associate reduction operation across all tasks in the group and place the result in one task